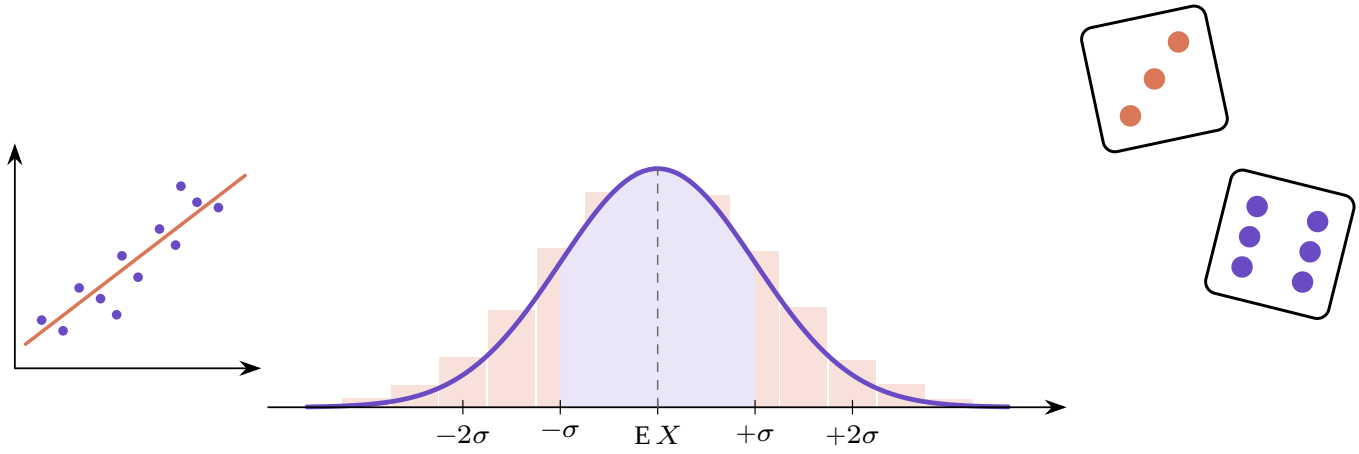
Теория вероятностей и статистика



Содержание

1 Ковариация и корреляция 3
- 1.1 Свойства математического ожидания и дисперсии . . . 3
- 1.2 Ковариация и коэффициент корреляции . . . 3

2 Реальные (выборочные) модели 4
- 2.1 Диаграмма рассеивания . . . 4
- 2.2 Метод наименьших квадратов для линейной регрессии . . . 5

3 Закон больших чисел 6
- 3.1 Неравенство Маркова . . . 6
- 3.2 Неравенство Чебышёва . . . 6
- 3.3 Следствия . . . 6

4 Схема Бернулли (биномиальное распределение) 7
- 4.1 Частота появления события . . . 8

5 Теорема Чебышёва 9

6 Геометрическое распределение 10
- 6.1 Математическое ожидание . . . 10
- 6.2 Дисперсия . . . 11

1 Ковариация и корреляция

1.1 Свойства математического ожидания и дисперсии

Для любых случайных величин X, Y и чисел a, b:

$$\boxed{\mathrm{E}(aX+bY) = a\,\mathrm{E}(X) + b\,\mathrm{E}(Y), \qquad \mathrm{D}(aX+bY) = a^2\,\mathrm{D}(X) + b^2\,\mathrm{D}(Y) + 2ab\,\mathrm{cov}(X,Y).}$$

Замечание. Если X и Y независимы, то $\mathrm{cov}(X,Y) = 0$ и $\mathrm{D}(aX+bY) = a^2\,\mathrm{D}(X) + b^2\,\mathrm{D}(Y)$. В частности, $\mathrm{D}(X+Y) = \mathrm{D}(X-Y) = \mathrm{D}(X) + \mathrm{D}(Y)$: **при вычитании дисперсии складываются**.

1.2 Ковариация и коэффициент корреляции

Определение (ковариация). **Ковариацией** случайных величин X и Y называется число

$$\mathrm{cov}(X,Y) = \mathrm{E}\big[(X - \mathrm{E}\,X)(Y - \mathrm{E}\,Y)\big] = \mathrm{E}(XY) - \mathrm{E}(X)\,\mathrm{E}(Y).$$

Определение (коэффициент корреляции).

$$\rho(X,Y) = \frac{\mathrm{cov}(X,Y)}{\sigma(X)\,\sigma(Y)} = \frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{D}(X)\,\mathrm{D}(Y)}}, \qquad -1 \le \rho(X,Y) \le 1.$$

Отсюда $\mathrm{cov}(X,Y) = \rho(X,Y)\sqrt{\mathrm{D}(X)\,\mathrm{D}(Y)}$ и $\mathrm{E}(XY) = \mathrm{cov}(X,Y) + \mathrm{E}(X)\,\mathrm{E}(Y)$.

Связь с независимостью. Если X и Y независимы, то $\mathrm{cov}(X,Y) = 0$ и $\rho(X,Y) = 0$. Следовательно, если $\rho(X,Y) \neq 0$, то X и Y **зависимы**.

Индикаторы событий. Пусть A, B — индикаторы событий (принимают значение 1, если событие произошло, и 0 иначе). Тогда $\mathrm{E}(A) = \mathrm{P}(A)$, $\mathrm{D}(A) = \mathrm{P}(A)(1-\mathrm{P}(A))$, а произведение $AB = 1$ только если $A = 1$ и $B = 1$, поэтому

$$\mathrm{E}(AB) = \mathrm{P}(AB) = \mathrm{cov}(A,B) + \mathrm{P}(A)\,\mathrm{P}(B).$$

2 Реальные (выборочные) модели

Определение (выборка). Выборкой, связанной с совместным наблюдением случайных величин X и Y, будем называть N пар значений

$$(x_1, y_1),\ (x_2, y_2),\ \dots,\ (x_N, y_N)$$

таких, что $x_1, \dots, x_N$ имеют такое же распределение, что и X, а $y_1, \dots, y_N$ — такое же распределение, что и Y.

Каждой характеристике вероятностной модели соответствует её выборочный аналог:

Вероятностная модель	Реальная (выборочная) модель
$\mathrm{E}(X)$	$\bar{x} = \dfrac{x_1 + \dots + x_N}{N}$
$\mathrm{D}(X)$	$S_x^2 = \dfrac{(x_1 - \bar{x})^2 + \dots + (x_N - \bar{x})^2}{N} = \overline{x^2} - \bar{x}^{\,2}$
$\sigma(X)$	$S_x = \sqrt{S_x^2}$
$\mathrm{cov}(X, Y)$	$C_{xy} = \dfrac{(x_1 - \bar{x})(y_1 - \bar{y}) + \dots + (x_N - \bar{x})(y_N - \bar{y})}{N} = \overline{xy} - \bar{x}\,\bar{y}$
$\rho(X, Y)$	$R_{xy} = \dfrac{C_{xy}}{S_x S_y}$

Таблица 1. Характеристики вероятностной модели и их выборочные аналоги

2.1 Диаграмма рассеивания

Зависимость между величинами удобно изучать с помощью **диаграммы рассеивания** (облака рассеивания): каждая пара (x_i, y_i) изображается точкой на координатной плоскости. Если точки группируются вдоль прямой, зависимость близка к линейной, и её можно описать уравнением $y = ax + b$.

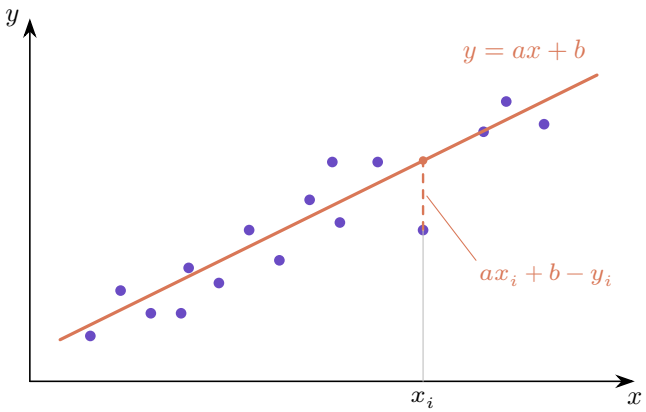


Рис. 1. Диаграмма рассеивания и прямая регрессии

2.2 Метод наименьших квадратов для линейной регрессии

Подбираем прямую $y = ax + b$ так, чтобы сумма квадратов отклонений была минимальной:

$$S(a,b) = (ax_1 + b - y_1)^2 + (ax_2 + b - y_2)^2 + \cdots + (ax_N + b - y_N)^2 \longrightarrow \min.$$

Найти минимум можно двумя способами: через частные производные или *выделением полных квадратов*. Разберём второй.

Раскроем скобки:

$$S(a,b) = (y_1^2 + \cdots + y_N^2) + a^2(x_1^2 + \cdots + x_N^2) + Nb^2 \\ - 2a(x_1y_1 + \cdots + x_Ny_N) - 2b(y_1 + \cdots + y_N) + 2ab(x_1 + \cdots + x_N).$$

Разделим на N:

$$\frac{S(a,b)}{N} = \overline{y^2} + a^2\,\overline{x^2} + b^2 - 2a\,\overline{xy} - 2b\,\bar{y} + 2ab\,\bar{x}.$$

Выделим полный квадрат по b, используя равенства

$$\overline{x^2} = S_x^2 + \bar{x}^2, \qquad \overline{y^2} = S_y^2 + \bar{y}^2, \qquad \overline{xy} = C_{xy} + \bar{x}\,\bar{y}:$$

$$\frac{S(a,b)}{N} = (a\bar{x} + b - \bar{y})^2 + a^2S_x^2 - 2aC_{xy} + S_y^2.$$

Теперь выделим полный квадрат по a:

$$\frac{S(a,b)}{N} = (a\bar{x} + b - \bar{y})^2 + \Big(aS_x - \frac{C_{xy}}{S_x}\Big)^2 \underbrace{- \frac{C_{xy}^2}{S_x^2} + S_y^2}_{\text{const}}.$$

Минимум достигается, когда оба квадрата равны нулю:

$$\begin{cases} a\bar{x} + b - \bar{y} = 0, \\ aS_x - \dfrac{C_{xy}}{S_x} = 0. \end{cases}$$

Коэффициенты прямой регрессии.

$$a = \frac{C_{xy}}{S_x^2} = R_{xy}\frac{S_y}{S_x}, \qquad b = \bar{y} - a\bar{x} = \bar{y} - R_{xy}\frac{S_y}{S_x}\,\bar{x}.$$

Замечание. Прямая регрессии всегда проходит через точку $(\bar{x}, \bar{y})$ — «центр» облака рассеивания.

3 Закон больших чисел

3.1 Неравенство Маркова

Неравенство Маркова. Пусть случайная величина $X \geq 0$. Тогда для любого $\varepsilon > 0$

$$\mathrm{P}(X \geq \varepsilon) \leq \frac{\mathrm{E}(X)}{\varepsilon}.$$

Доказательство. Пусть X принимает значения $x_1, \dots, x_n$ с вероятностями $p_1, \dots, p_n$, причём $x_1, \dots, x_k < \varepsilon$, а $x_{k+1}, \dots, x_n \geq \varepsilon$. Тогда

$$\mathrm{E}(X) = x_1 p_1 + \dots + x_n p_n = S_1 + S_2, \qquad S_1 = x_1 p_1 + \dots + x_k p_k, \quad S_2 = x_{k+1} p_{k+1} + \dots + x_n p_n.$$

Так как $X \geq 0$, то $S_1 \geq 0$, $S_2 \geq 0$, и

$$\mathrm{E}(X) \geq S_2 \geq \varepsilon (p_{k+1} + \dots + p_n) = \varepsilon \ \mathrm{P}(X \geq \varepsilon).$$

Отсюда $\mathrm{P}(X \geq \varepsilon) \leq \dfrac{\mathrm{E}(X)}{\varepsilon}$. ■

3.2 Неравенство Чебышёва

Неравенство Чебышёва. Пусть случайная величина X имеет математическое ожидание $\mathrm{E}(X)$ и дисперсию $\mathrm{D}(X)$. Тогда для любого $\varepsilon > 0$

$$\mathrm{P}(|X - \mathrm{E}(X)| \geq \varepsilon) \leq \frac{\mathrm{D}(X)}{\varepsilon^2}.$$

Доказательство. Рассмотрим $Y = (X - \mathrm{E}(X))^2 \geq 0$; заметим, что $\mathrm{E}(Y) = \mathrm{D}(X)$. По неравенству Маркова

$$\mathrm{P}(Y \geq \varepsilon^2) \leq \frac{\mathrm{E}(Y)}{\varepsilon^2} \implies \mathrm{P}((X - \mathrm{E}(X))^2 \geq \varepsilon^2) \leq \frac{\mathrm{D}(X)}{\varepsilon^2} \implies \mathrm{P}(|X - \mathrm{E}(X)| \geq \varepsilon) \leq \frac{\mathrm{D}(X)}{\varepsilon^2}.$$ ■

Эквивалентная форма (для противоположного события):

$$\boxed{\mathrm{P}(|X - \mathrm{E}(X)| < \varepsilon) \geq 1 - \frac{\mathrm{D}(X)}{\varepsilon^2}.}$$

Замечание. Неравенство Чебышёва даёт, как правило, более точную оценку, чем неравенство Маркова, так как учитывает разброс величины (дисперсию).

3.3 Следствия

1) Пусть $X \geq 0$ и $\mathrm{E}(X) = a$. Тогда для $k \in \mathbb{N}$

$$\mathrm{P}(X \geq ka) \leq \frac{a}{ka} = \frac{1}{k}.$$

2) **Правило k сигм.** Подставим $\varepsilon = k\sigma$ в неравенство Чебышёва:

$$\mathrm{P}(|X - \mathrm{E}\,X| \geq 2\sigma) \leq \frac{\sigma^2}{4\sigma^2} = \frac{1}{4}, \qquad \mathrm{P}(|X - \mathrm{E}\,X| \geq 3\sigma) \leq \frac{1}{9}, \qquad \mathrm{P}(|X - \mathrm{E}\,X| \geq 4\sigma) \leq \frac{1}{16}.$$

Правило трёх сигм. Для нормально распределённой величины оценка намного точнее: с вероятностью $\approx 0{,}997$

$$X \in [\mathrm{E}(X) - 3\sigma;\ \mathrm{E}(X) + 3\sigma].$$

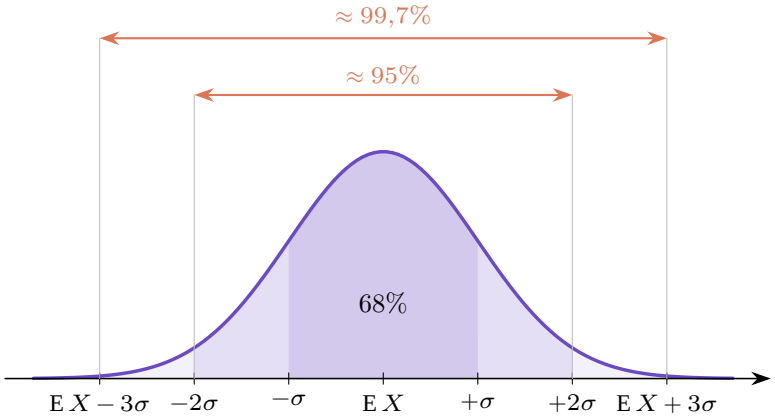


Рис. 2. Правило трёх сигм для нормального распределения

4 Схема Бернулли (биномиальное распределение)

Проводится n независимых одинаковых испытаний, в каждом из которых возможен «успех» с вероятностью p или «неудача» с вероятностью $q = 1 - p$.

Определение (формула Бернулли). Вероятность того, что в n испытаниях произойдёт ровно k успехов:

$$P_n(S = k) = C_n^k\, p^k q^{n-k},$$

где n — число испытаний, k — число успехов, p — вероятность успеха, $q = 1 - p$ — вероятность неудачи.

Пусть S — случайная величина, обозначающая число успехов в испытаниях Бернулли. Её закон распределения называется **биномиальным**:

$$S \sim \begin{pmatrix} 0 & 1 & 2 & \dots & k & \dots & n \\ q^n & C_n^1 p q^{n-1} & C_n^2 p^2 q^{n-2} & \dots & C_n^k p^k q^{n-k} & \dots & p^n \end{pmatrix}.$$

Биномиальное распределение, $n = 10$, $p = 0{,}3$

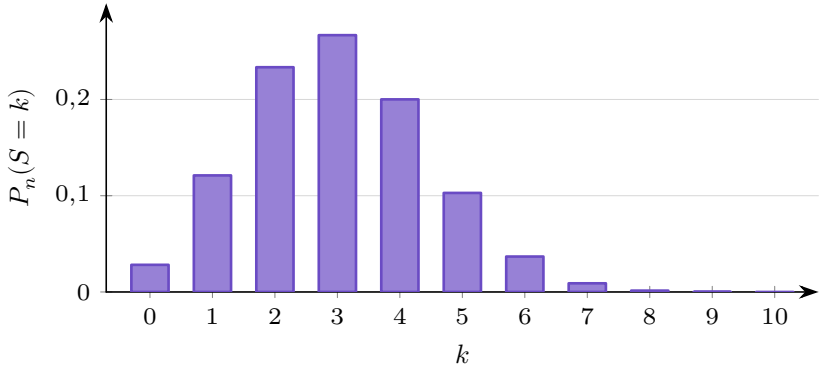


Рис. 3. Биномиальное распределение

Теорема. Пусть S — случайная величина, имеющая биномиальное распределение. Тогда

$$\mathrm{E}(S) = np, \qquad \mathrm{D}(S) = npq,$$

где n — число испытаний, p — вероятность успеха в отдельном испытании, q — вероятность неудачи.

Доказательство. Пусть S_1 — число успехов в 1-м испытании:

$$S_1 \sim \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix} \implies \mathrm{E}(S_1) = p, \qquad \mathrm{D}(S_1) = \mathrm{E}(S_1^2) - \mathrm{E}^2(S_1) = p - p^2 = p(1-p) = pq.$$

Аналогично для $S_2, S_3, \dots, S_n$. Так как $S = S_1 + S_2 + \cdots + S_n$, то

$$\mathrm{E}(S) = \mathrm{E}(S_1) + \cdots + \mathrm{E}(S_n) = np, \qquad \mathrm{D}(S) = \mathrm{D}(S_1) + \cdots + \mathrm{D}(S_n) = npq,$$

где дисперсии складываются, *так как испытания независимы*. ■

4.1 Частота появления события

Рассмотрим серию из N одинаковых опытов, в каждом из которых может произойти событие A с вероятностью p. Пусть S — число появлений события A; тогда $\mathrm{E}(S) = Np$, $\mathrm{D}(S) = Npq$.

Рассмотрим случайную величину $Y = \dfrac{S}{N}$ — **частоту** появления успеха:

$$\mathrm{E}(Y) = \mathrm{E}\Big(\frac{S}{N}\Big) = \frac{1}{N}\,pN = p, \qquad \mathrm{D}(Y) = \mathrm{D}\Big(\frac{S}{N}\Big) = \frac{1}{N^2}\,Npq = \frac{pq}{N} \xrightarrow[N\to\infty]{} 0.$$

По неравенству Чебышёва для любого $\varepsilon > 0$:

$$\mathrm{P}(|Y - p| \ge \varepsilon) \le \frac{\mathrm{D}(Y)}{\varepsilon^2} = \frac{pq}{N\varepsilon^2} \xrightarrow[N\to\infty]{} 0, \qquad \mathrm{P}(|Y - p| < \varepsilon) \ge 1 - \frac{pq}{N\varepsilon^2} \xrightarrow[N\to\infty]{} 1.$$

Теорема Бернулли. С вероятностью, сколь угодно близкой к 1, можно утверждать, что при достаточно большом числе испытаний N частота случайного события будет сколь угодно мало отличаться от его вероятности.

Полезные формулы для числа успехов X

$$\mathrm{P}(|X - np| \ge \varepsilon) \le \frac{npq}{\varepsilon^2}, \qquad \mathrm{P}\Big(\Big|\frac{X}{N} - p\Big| \ge \varepsilon\Big) \le \frac{pq}{N\varepsilon^2}.$$

Так как $pq = p(1-p) \le \frac{1}{4}$, вторую оценку можно заменить на $\dfrac{1}{4N\varepsilon^2}$, если p неизвестно.

5 Теорема Чебышёва

Теорема Чебышёва. С вероятностью, сколь угодно близкой к 1, можно утверждать, что при достаточно большом числе независимых опытов N среднее арифметическое полученных значений случайной величины будет сколь угодно мало отличаться от её математического ожидания.

Доказательство. Пусть $\mathrm{E}(X) = m$, $\mathrm{D}(X) = d$, а $X_1, \dots, X_N$ — значения X в независимых опытах. Рассмотрим среднее $\bar{X} = \dfrac{X_1 + X_2 + \dots + X_N}{N}$. Тогда

$$\mathrm{E}(\bar{X}) = \frac{1}{N}(\mathrm{E}(X_1) + \dots + \mathrm{E}(X_N)) = \frac{Nm}{N} = m,$$

$$\mathrm{D}(\bar{X}) = \frac{1}{N^2}(\mathrm{D}(X_1) + \dots + \mathrm{D}(X_N)) = \frac{Nd}{N^2} = \frac{d}{N} \xrightarrow[N\to\infty]{} 0$$

(дисперсии складываются в силу независимости). По неравенству Чебышёва для любого $\varepsilon > 0$:

$$\mathrm{P}(|\bar{X} - m| \geq \varepsilon) \leq \frac{d}{N\varepsilon^2} \implies \mathrm{P}(|\bar{X} - m| < \varepsilon) \geq 1 - \frac{d}{N\varepsilon^2} \xrightarrow[N\to\infty]{} 1. \qquad \blacksquare$$

Замечание. Теорема Бернулли — частный случай теоремы Чебышёва: частота $\frac{S}{N}$ есть среднее арифметическое индикаторов успеха $S_1, \dots, S_N$, у которых $m = p$, $d = pq$.

6 Геометрическое распределение

Испытания Бернулли проводятся *до первого успеха*. Пусть X — номер испытания, в котором впервые произошёл успех.

Определение (геометрическое распределение).

$$\mathrm{P}(X = k) = p\,q^{k-1}, \qquad k = 1, 2, 3, \ldots,$$

где p — вероятность успеха, $q = 1 - p$, испытания независимы.

$$X \sim \begin{pmatrix} 1 & 2 & 3 & \ldots & k & \ldots \\ p & pq & pq^2 & \ldots & pq^{k-1} & \ldots \end{pmatrix}$$

Проверим, что сумма вероятностей равна 1 (геометрическая прогрессия):

$$p + pq + pq^2 + \cdots + pq^{k-1} + \cdots = p(1 + q + q^2 + \ldots) = p \cdot \frac{1}{1-q} = 1.$$

Геометрическое распределение, $p = 0{,}4$

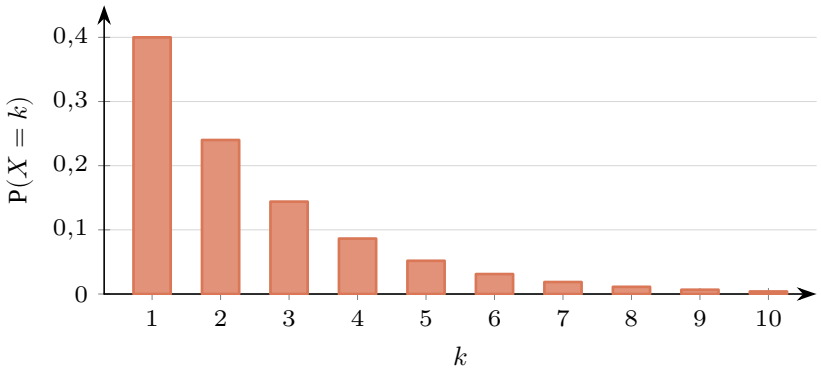


Рис. 4. Геометрическое распределение

6.1 Математическое ожидание

$$\mathrm{E}(X) = 1 \cdot p + 2 \cdot pq + 3 \cdot pq^2 + \cdots + k\,pq^{k-1} + \ldots$$

Разобьём каждое слагаемое: $2pq = pq + pq$, $3pq^2 = pq^2 + 2pq^2$, $4pq^3 = pq^3 + 3pq^3$ и т. д. Тогда

$$\mathrm{E}(X) = \underbrace{(p + pq + pq^2 + \ldots)}_{=1} + q\,\underbrace{(p + 2pq + 3pq^2 + \ldots)}_{=\mathrm{E}(X)} = 1 + q\,\mathrm{E}(X).$$

Отсюда $\mathrm{E}(X)(1 - q) = 1$, то есть

$$\boxed{\mathrm{E}(X) = \frac{1}{p}.}$$

6.2 Дисперсия

$\mathrm{D}(X) = \mathrm{E}(X^2) - \mathrm{E}^2(X)$. Найдём

$$\mathrm{E}(X^2) = 1 \cdot p + 4pq + 9pq^2 + 16pq^3 + \ldots$$

Разобьём: $4pq = pq + 3pq$, $9pq^2 = 4pq^2 + 5pq^2$, $16pq^3 = 9pq^3 + 7pq^3$, … (здесь $3 = 2 \cdot 2 - 1$, $5 = 2 \cdot 3 - 1$, $7 = 2 \cdot 4 - 1$, т. е. $k^2 = (k-1)^2 + (2k-1)$). Тогда

$$\begin{aligned}\mathrm{E}(X^2) &= q\underbrace{(p + 4pq + 9pq^2 + \ldots)}_{\mathrm{E}(X^2)} + \underbrace{(p + 3pq + 5pq^2 + 7pq^3 + \ldots)}_{\mathrm{E}(2X-1)} \\ &= q\,\mathrm{E}(X^2) + 2\,\mathrm{E}(X) - 1 = q\,\mathrm{E}(X^2) + \frac{2}{p} - 1.\end{aligned}$$

Значит, $p\,\mathrm{E}(X^2) = \dfrac{2}{p} - 1$ и $\mathrm{E}(X^2) = \dfrac{2}{p^2} - \dfrac{1}{p}$. Окончательно

$$\mathrm{D}(X) = \frac{2}{p^2} - \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}, \qquad \boxed{\mathrm{D}(X) = \frac{q}{p^2}.}$$

Итог. Для геометрического распределения:

$$\mathrm{P}(X = k) = pq^{k-1}, \qquad \mathrm{E}(X) = \frac{1}{p}, \qquad \mathrm{D}(X) = \frac{q}{p^2}, \qquad \mathrm{P}(X \le k) = 1 - q^k.$$